

REDES NEURONALES ARTIFICIALES.

RNA HISTORIA

- 1936 - Alan Turing. Fue el primero en estudiar el cerebro como una forma de ver el mundo de la computación.
- Sin embargo, los primeros teóricos que concibieron los fundamentos de la computación neuronal fueron Warren McCulloch, un neurofisiólogo, y Walter Pitts, un matemático, quienes, en 1943, lanzaron una teoría acerca de la forma de trabajar de las neuronas (Un Cálculo Lógico de la Inminente Idea de la Actividad Nerviosa - Boletín de Matemática Biofísica 5: 115-133). Ellos modelaron una red neuronal simple mediante circuitos eléctricos.

RNA HISTORIA

- 1949 - Donald Hebb. Fue el primero en explicar los procesos del aprendizaje (que es el elemento básico de la inteligencia humana) desde un punto de vista psicológico, desarrollando una regla de cómo el aprendizaje ocurría. Aún hoy, este es el fundamento de la mayoría de las funciones de aprendizaje que pueden hallarse en una red neuronal. Su idea fue que el aprendizaje ocurría cuando ciertos cambios en una neurona eran activados. También intentó encontrar semejanzas entre el aprendizaje y la actividad nerviosa. Los trabajos de Hebb formaron las bases de la Teoría de las Redes Neuronales.

RNA HISTORIA

- 1950 - Karl Lashley. En sus series de ensayos, encontró que la información no era almacenada en forma centralizada en el cerebro sino que era distribuida encima de él.
- 1956 - Congreso de Dartmouth. Este Congreso frecuentemente se menciona para indicar el nacimiento de la inteligencia artificial.

RNA HISTORIA

- 1957 - Frank Rosenblatt. Comenzó el desarrollo del Perceptron. Esta es la red neuronal más antigua; utilizándose hoy en día para aplicación como identificador de patrones. Este modelo era capaz de generalizar, es decir, después de haber aprendido una serie de patrones podía reconocer otros similares, aunque no se le hubiesen presentado en el entrenamiento. Sin embargo, tenía una serie de limitaciones, por ejemplo, su incapacidad para resolver el problema de la función OR-exclusiva y, en general, era incapaz de clasificar clases no separables linealmente.

RNA HISTORIA

- 1959 - Frank Rosenblatt: Principios de Neurodinámica. En este libro confirmó que, bajo ciertas condiciones, el aprendizaje del Perceptrón convergía hacia un estado finito (Teorema de Convergencia del Perceptrón).

RNA HISTORIA

- 1960 - Bernard Widroff/Marcian Hoff. Desarrollaron el modelo Adaline (ADaptative LINear Elements). Esta fue la primera red neuronal aplicada a un problema real (filtros adaptativos para eliminar ecos en las líneas telefónicas) que se ha utilizado comercialmente durante varias décadas.

RNA HISTORIA

- 1961 - Karl Steinbeck: Die Lernmatrix. Red neuronal para simples realizaciones técnicas (memoria asociativa).
- 1969 - Marvin Minsky/Seymour Papert. En este año casi se produjo la “muerte abrupta” de las Redes Neuronales; ya que Minsky y Papert probaron (matemáticamente) que el Perceptrón no era capaz de resolver problemas relativamente fáciles, tales como el aprendizaje de una función no-lineal. Esto demostró que el Perceptrón era muy débil, dado que las funciones no-lineales son extensamente empleadas en computación y en los problemas del mundo real.

RNA HISTORIA

- 1974 - Paul Werbos. Desarrolló la idea básica del algoritmo de aprendizaje de propagación hacia atrás (backpropagation); cuyo significado quedó definitivamente aclarado en 1985.
- 1977 - Stephen Grossberg: Teoría de Resonancia Adaptada (TRA). La Teoría de Resonancia Adaptada es una arquitectura de red que se diferencia de todas las demás previamente inventadas. La misma simula otras habilidades del cerebro: memoria a largo y corto plazo.

RNA HISTORIA

- 1985 - John Hopfield. Provocó el renacimiento de las redes neuronales con su libro: “Computación neuronal de decisiones en problemas de optimización.”
- 1986 - David Rumelhart/G. Hinton. Redescubrieron el algoritmo de aprendizaje de propagación hacia atrás (backpropagation).

RNA HISTORIA

- A partir de 1986, el panorama fue alentador con respecto a las investigaciones y el desarrollo de las redes neuronales. En la actualidad, son numerosos los trabajos que se realizan y publican cada año, las aplicaciones nuevas que surgen (sobre todo en el área de control) y las empresas que lanzan al mercado productos nuevos, tanto hardware como software (sobre todo para simulación).

RNA DEFINICIONES

- Existen numerosas formas de definir a las redes neuronales; desde las definiciones cortas y genéricas hasta las que intentan explicar más detalladamente qué son las redes neuronales.
- Por ejemplo: 1) Una nueva forma de computación, inspirada en modelos biológicos.
- 2) Un modelo matemático compuesto por un gran número de elementos procesales organizados en niveles.

RNA DEFINICIONES

- 3) ...un sistema de computación compuesto por un gran número de elementos simples, elementos de procesos muy interconectados, los cuales procesan información por medio de su estado dinámico como respuesta a entradas externas.
- 4) Redes neuronales artificiales son redes interconectadas masivamente en paralelo de elementos simples (usualmente adaptativos) y con organización jerárquica, las cuales intentan interactuar con los objetos del mundo real del mismo modo que lo hace el sistema nervioso biológico.

RNA VENTAJAS

Son capaces de aprender de la experiencia, de generalizar de casos anteriores a nuevos casos, de abstraer características esenciales a partir de entradas que representan información irrelevante, etc.

Esto hace que ofrezcan numerosas ventajas y que este tipo de tecnología se esté aplicando en múltiples áreas. Entre las ventajas se incluyen:

RNA VENTAJAS

Aprendizaje Adaptativo. Capacidad de aprender a realizar tareas basadas en un entrenamiento o en una experiencia inicial.

Auto-organización. Una red neuronal puede crear su propia organización o representación de la información que recibe mediante una etapa de aprendizaje.

Tolerancia a fallos. La destrucción parcial de una red conduce a una degradación de su estructura; sin embargo, algunas capacidades de la red se pueden retener, incluso sufriendo un gran daño.

RNA VENTAJAS

Operación en tiempo real. Los cálculos neuronales pueden ser realizados en paralelo; para esto se diseñan y fabrican máquinas con hardware especial para obtener esta capacidad.

Fácil inserción dentro de la tecnología existente. Se pueden obtener chips especializados para redes neuronales que mejoran su capacidad en ciertas tareas. Ello facilitará la integración modular en los sistemas existentes.

RNA VENTAJAS

Operación en tiempo real. Los cálculos neuronales pueden ser realizados en paralelo; para esto se diseñan y fabrican máquinas con hardware especial para obtener esta capacidad.

Fácil inserción dentro de la tecnología existente. Se pueden obtener chips especializados para redes neuronales que mejoran su capacidad en ciertas tareas. Ello facilitará la integración modular en los sistemas existentes.

RNA

Están inspiradas en las redes neuronales biológicas del cerebro humano.


Las redes neuronales artificiales presentan una serie de características propias del cerebro.

Estas redes aprenden de la experiencia, generalizan de ejemplos previos a ejemplos nuevos y abstraen las características principales de una serie de datos.


Son sistemas inteligentes que permiten tomar decisiones de una manera similar a como lo hacemos los humanos.

RNA - NEURONAS

Las neuronas son unidades fundamentales del cerebro y del sistema nervioso, responsables de la recepción de los inputs sensoriales del mundo exterior, así como de enviar órdenes a distintas partes del cuerpo.




RNA - NEURONAS




RNA - NEURONAS

Es un modelo matemático que recibe entradas externas o de otras neuronas, las combina y produce una salida, creado con la finalidad de llevar a cabo tareas.



RNA - NEURONAS


Es un modelo matemático que recibe entradas externas o de otras neuronas, las combina y produce una salida, creado con la finalidad de llevar a cabo tareas.



RNA

Las redes neuronales son un paradigma de aprendizaje y procesamiento automático basado en el funcionamiento del sistema nervioso.


Se compone por una serie de neuronas y conexiones que colaboran entre sí para producir una salida.




RNA PUEDE.....

- Reconocer texto.
- Reconocer voz.
- Reconocer caras de personas.
- Reconocer huella dactilar
- Clasificar imágenes para detectar enfermedades.
- Realizar predicciones.
- Traducir idiomas.
- Prevenir fraudes.
- Realizar análisis genético.
- Reconocimiento de patrones.

RNA PUEDE.....



CONVOLUTIONAL NEURAL NETWORKS.




CNN

- La CNN es un tipo de Red Neuronal Artificial con aprendizaje supervisado que procesa sus capas imitando al cortex visual del ojo humano para identificar distintas características en las entradas que en definitiva hacen que pueda identificar objetos y “ver”.
- Para ello, la CNN contiene varias capas ocultas especializadas y con una jerarquía: esto quiere decir que **las primeras capas pueden detectar líneas, curvas y se van especializando** hasta llegar a capas más profundas que reconocen formas complejas como un rostro o la silueta de un animal.

CNN

- Recordemos que la red neuronal deberá aprender por sí sola a reconocer una diversidad de objetos dentro de imágenes y para ello necesitaremos una gran cantidad de imágenes, para que la red pueda captar sus características únicas -de cada objeto- y a su vez, poder generalizarlo.

CNN




CNN

- Los algoritmos de redes neuronales están diseñados para imitar el comportamiento del cerebro humano; el propósito de estas generalmente se reduce a 3 aspectos:
 - Aprender de la experiencia
 - Obtener información según las entradas que se proveen
 - Generalizar lo ya aprendido en nuevos elementos.
-
- Lo que las hace muy valiosas ya que permiten reconocer patrones que de otro modo no podrían ser reconocidos.

CNN


- Las redes neuronales se encuentran conformadas por capas que a su vez cuentan con “neuronas” quienes se conectarán entre sí para enviarse mensajes y poder compartir información que será relevante para determinar el o los outputs correspondientes.

CNN




En la capa de input estarán todas nuestras entradas o datos de entrenamiento estos contarán con pesos que permitirán expresar su importancia.


La capa hidden puede estar conformada a su vez por una o varias capas el número de capas dependerá de qué tan sofisticado queremos nuestro modelo sin embargo, es necesario recalcar que mientras más capas se tengan necesitaremos más recursos como tiempo y poder computacional.



CNN



output layer




La capa de output puede contar con una o varias neuronas dependerá del número de características que se desean llegar a encontrar.

Funciones de Activación

- La función de activación devuelve una salida que será generada por la neurona dada una entrada o conjunto de entradas.
- Cada una de las capas que conforman la red neuronal tienen una función de activación que permitirá reconstruir o predecir.
- Además, se debe considerar que en la red neuronal se usará una función no lineal debido a que le permite al el modelo adaptarse para trabajar con la mayor cantidad de datos.
- Las funciones de activación se dividen en dos tipos como: lineal y no lineal.

Funciones de Activación Lineal.




Esta función también conocida como identidad, permite que lo de la entrada sea igual a la salida por lo que si tengo un red neuronal de varias capas y aplicó función lineal se dice que es una regresión lineal.

Por lo tanto, esta función de activación lineal se usa si a la salida se requiere una regresión lineal y de esta manera a la red neuronal que se le aplica la función va a generar un valor único.
Por ejemplo se usa cuando se solicita predecir el valor de un número de ventas.

Funciones de Activación

No Lineal.




Función Umbral

Esta función también conocida como escalón, indica que si la x es menor que cero la neurona va a ser cero pero cuando es mayor igual a cero dará como salida igual 1.

Esta función se usa cuando se quiere clasificar o cuando se tiene salidas categóricas. **Por ejemplo, se puede usar para predecir si compro algo o no.**

Funciones de Activación

No Lineal.



$$f(x) = \frac{1}{1 + e^{-x}}$$

Función Sigmoide

Esta función también conocida como función logística, está en un rango de valores de salida entre cero y uno por lo que la salida es interpretada como una probabilidad.


Si se evalúa la función con valores de entrada muy negativos, es decir $x < 0$ la función será igual a cero, si se evalúa en cero la función dará 0.5 y en valores altos su valor es aproximadamente a 1.

Por lo que esta función se usa en la última capa y se usa para clasificar datos en dos categorías.

Funciones de Activación

No Lineal.

Función tangente hiperbólica




Esta función de activación llamada tangente hiperbólica tiene un rango de valores de salida entre -1 y 1.

Se dice que esta función es un escalamiento de la función logística, por lo que a pesar que esta función está centrada tiene un problema similar a la sigmoide debido al problema de desaparición del gradiente, que se da cuando en el entrenamiento se genera un error con el algoritmo de propagación hacia atrás y debido a esto el error se va propagando entre las capas, por lo que en cada iteración toma un valor pequeño y la red no puede obtener un buen aprendizaje.

Funciones de Activación

No Lineal.

Función ReLu



Esta función es la más utilizada debido a que permite el aprendizaje muy rápido en las redes neuronales.


Si a esta función se le da valores de entrada muy negativos el resultado es cero pero si se le da valores positivos queda igual y además el gradiente de esta función será cero en el segundo cuadrante y uno en el primer cuadrante.

Cuando se tiene que la función es igual a cero y su derivada también lo es se genera lo que es la muerte de neuronas, a pesar que puede ser un inconveniente en algunos casos permite la regularización Dropout.

Por esta razón la función ReLu tiene una variante denominada Leaky ReLu que va a prevenir que existan neuronas muertas debido a la pequeña pendiente que existe cuando $x < 0$.

Funciones de Activación No Lineal.

Función Leaky ReLu




Cuando se tiene que la función es igual a cero y su derivada también lo es se genera lo que es la muerte de neuronas, a pesar que puede ser un inconveniente en algunos casos permite la regularización Dropout.

Por esta razón la función ReLu tiene una variante denominada Leaky ReLu que va a prevenir que existan neuronas muertas debido a la pequeña pendiente que existe cuando $x < 0$.

Funciones de Activación

No Lineal.

Función Softmax



En otras palabras, Softmax se usa para clases múltiples y cuando se va a asignar probabilidades a cada clase que pertenezca a clases múltiples.

Esta función se usa para clasificar data, por ejemplo si le damos de entrada la imagen de una fruta y se solicita saber el tipo de fruta a que pertenece, aplicando softmax la red nos dará la probabilidad de que puede ser 0.3 o 30% melón, 0.2 o 20% sandía y 0.5 o 50% papaya, por lo que nos el resultado será el que tenga mayor probabilidad y cabe recalcar que la suma de estas probabilidades será igual a 1

CNN



Una imagen...

		0.6	0.6			
	0.6			0.6		
	0.6	0.6	0.6	0.6		
	0.6			0.6		

...es una matriz de pixeles.

El valor de los pixeles va de 0 a 255 pero se normaliza para la red neuronal de 0 a 1

CNN (Procedimiento)

- Para comenzar, la red toma como entrada los pixeles de una imagen.
- Si tenemos una imagen con apenas 28×28 pixeles de alto y ancho, eso equivale a 784 neuronas. Y eso es si sólo tenemos 1 color (escala de grises).
- Si tuviéramos una imagen a color, necesitaríamos 3 canales (red, green, blue) y entonces usaríamos $28 \times 28 \times 3 = 2352$ neuronas de entrada.
- Esa es nuestra capa de entrada. Para continuar con el ejemplo, supondremos que utilizamos la imagen con 1 sólo color.

CNN (Procedimiento)

PRE-PROCESAMIENTO

- Antes de alimentar la red, recuerda que como entrada nos conviene normalizar los valores.
- Los colores de los pixeles tienen valores que van de 0 a 255, haremos una transformación de cada pixel: “ $\text{valor}/255$ ” y nos quedará siempre un valor entre 0 y 1.

CNN (Procedimiento)

PRE-PROCESAMIENTO



		0.2	0.2		
	0.2			0.2	
	0.2	0.2	0.2	0.2	
	0.2			0.2	

		0.4	0.4		
	0.4			0.4	
	0.4	0.4	0.4	0.4	
	0.4			0.4	

		0.2	0.2		
	0.2			0.2	
	0.2	0.2	0.2	0.2	
	0.2			0.2	

Si la imagen es a color, estará compuesta de tres canales: rojo, verde, azul.

CNN (Procedimiento)

CONVOLUCIONES.

- Ahora comienza el “procesado distintivo” de las CNN.
- Es decir, haremos las llamadas “convoluciones”. Estas consisten en tomar “**grupos de pixeles cercanos**” de la imagen de entrada e ir operando matemáticamente (producto escalar) contra una pequeña matriz que se llama kernel.

CNN (Procedimiento)

CONVOLUCIONES.

- Ese kernel supongamos de tamaño 3×3 pixels “recorre” todas las neuronas de entrada (de izquierda-derecha, de arriba-abajo) y genera una nueva matriz de salida, que en definitiva será nuestra nueva capa de neuronas ocultas.
- Si la imagen fuera a color, el kernel realmente sería de $3 \times 3 \times 3$ es decir: un filtro con 3 kernels de 3×3 ; luego esos 3 filtros se suman (y se le suma una unidad bias) y conformarán 1 salida (cómo si fuera 1 solo canal).

CNN (Procedimiento)

CONVOLUCIONES

		0.6	0.6		
	0.6			0.6	
	0.6	0.6	0.6	0.6	
	0.6			0.6	

Imagen de
entrada

1	0	-1
2	0	-2
1	0	-1


kernel

El kernel tomará inicialmente valores aleatorios y se irán ajustando mediante backpropagation.

Una mejora es hacer que siga una distribución normal siguiendo simetrías, pero sus valores son aleatorios.

CNN (Procedimiento)

FILTROS. Conjunto de Kernels



A medida que vamos desplazando el kernel y vamos obteniendo una “nueva imagen” filtrada por el kernel. En esta primer convolución y siguiendo con el ejemplo anterior, es como si obtuviéramos 32 “imágenes filtradas nuevas”.

Estas imágenes nuevas lo que están “dibujando” son ciertas características de la imagen original. Esto ayudará en el futuro a poder distinguir un objeto de otro (por ej. gato ó perro).


CNN (Procedimiento)

FILTROS. Conjunto de Kernels

En realidad, no aplicaremos 1 sólo kernel, si no que tendremos muchos kernel (su conjunto se llama filtros).

Por ejemplo en esta primer convolución podríamos tener 32 filtros, con lo cual realmente obtendremos 32 matrices de salida (este conjunto se conoce como “feature mapping”)


Cada una de 28x28x1 dando un total del 25.088 neuronas para nuestra PRIMER CAPA OCULTA de neuronas



Aquí vemos al kernel realizando el producto matricial con la imagen de entrada y desplazando de a 1 pixel de izquierda a derecha y de arriba-abajo y va generando una nueva matriz que compone al mapa de features

CNN (Procedimiento)

FILTROS. Conjunto de Kernels



La imagen realiza una convolución con un kernel y aplica la función de activación, en este caso ReLu.

Subsampling

- Ahora viene un paso en el que reduciremos la cantidad de neuronas antes de hacer una nueva convolución.
- Ya que a partir de nuestra imagen blanco y negro de 28x28px tenemos una primer capa de entrada de 784 neuronas y luego de la primer convolución obtenemos una capa oculta de 25.088 neuronas -que realmente son nuestros 32 mapas de características de 28x28-

Subsampling

- Si hiciéramos una nueva convolución a partir de esta capa, el número de neuronas de la próxima capa incrementaría bastante, lo cual implica mayor procesamiento.
- Para reducir el tamaño de la próxima capa de neuronas haremos un proceso de subsampling en el que reduciremos el tamaño de nuestras imágenes filtradas pero en donde **deberán prevalecer las características más importantes que detectó cada filtro**

Subsampling

0	0	0,6	1,2
0	0,6	0	1,2
0	1,2	0	1,2
0	1,2	0	0,6

0,6	1,2
1,2	1,2

Luego de este proceso de subsampling nos quedarán 32 imágenes de 14×14 , pasando de haber tenido 25.088 neuronas a 6272, son bastantes menos y - en teoría- siguen almacenando la información más importante para detectar características deseadas.


SUBSAMPLING:

Aplico Max-Pooling de 2×2
y reduzco mi salida a la mitad

Subsampling


PRIMERA CONVOLUCIÓN

La primer convolución es capaz de detectar características primitivas como líneas ó curvas. **A medida que hacemos más capas con las convoluciones, los mapas de características serán capaces de reconocer formas más complejas, y el conjunto total de capas de convoluciones podrá “ver”.**



Subsampling

SEGUNDA CONVOLUCIÓN (y sucesivas)




La 3er convolución comenzará en tamaño 7×7 píxeles y luego del max-pooling quedará en 3×3 con lo cual podríamos hacer sólo 1 convolución más. En este ejemplo empezamos con una imagen de 28x28px e hicimos 3 convoluciones. Si la imagen inicial hubiese sido mayor (de 224x224px) aún hubiéramos podido seguir haciendo convoluciones.

Conectar con RN «tradicional»

Se toma la última capa oculta a la que se hizo en subsampling, la cual se dice que es “tridimensional” por tomar la forma -en nuestro ejemplo- 3x3x128 (alto, ancho, mapas) y la “aplanamos”, esto es que deja de ser tridimensional, y pasa a ser una capa de neuronas “tradicionales”, de las que ya conocíamos. Por ejemplo, podríamos aplanar (y conectar) a una nueva capa oculta de 100 neuronas.


ARQUITECTURA DE UNA CNN



Conectar con RN «tradicional»

Entonces, a esta nueva capa oculta “tradicional”, le aplicamos la función Softmax que conecta la capa de salida final que tendrá la cantidad de neuronas correspondientes con las clases que estamos clasificando. Si clasificamos perros y gatos, serán 2 neuronas. Si es el dataset Mnist numérico serán 10 neuronas de salida. Si clasificamos coches, aviones ó barcos serán 3, etc.

ARQUITECTURA DE UNA CNN



Conectar con RN «tradicional»

Las salidas al momento del entrenamiento tendrán el formato conocido como “one-hot-encoding”

Para perros y gatos será: $[1,0]$ y $[0,1]$

Para coches, aviones ó barcos será $[1,0,0]$; $[0,1,0]$; $[0,0,1]$.

Y la función de Softmax se encarga de pasar a probabilidad (entre 0 y 1) a las neuronas de salida.

Por ejemplo una salida $[0,2 \ 0,8]$ nos indica 20% probabilidades de que sea perro y 80% de que sea gato.

Comparativa

	Red Neuronal Tradicional	Red Neuronal Convolutacional
Datos de entrada en la Capa Inicial	Las características que analizamos. Por ejemplo: ancho, alto, grosor, etc.	Píxeles de una imagen. Si es color, serán 3 capas para rojo, verde, azul
Capas ocultas	Elegimos una cantidad de neuronas para las capas ocultas.	Tenemos de tipo: * Convolución (con un tamaño de kernel y una cantidad de filtros) * Subsampling
Capa de salida	La cantidad de neuronas que queremos clasificar. Para “comprar” ó “alquilar” serán 2 neuronas.	Debemos “aplanar” la última convolución con una (ó más) capas de neuronas ocultas “tradicionales” y hacer una salida mediante SoftMax a la capa de salida.
Aprendizaje	Supervisado	Supervisado

Comparativa

	Red Neuronal Tradicional	Red Neuronal Convolutacional
Interconexiones	Entre capas, todas las neuronas de una capa con la siguiente.	Son muchas menos conexiones necesarias, pues realmente los pesos que ajustamos serán los de los filtros/kernels que usamos.
Significado de la cantidad de capas ocultas	Realmente es algo desconocido y no representa algo en sí mismo.	Las capas ocultas son mapas de detección de características de la imagen y tienen jerarquía: primeras capas detectan líneas, luego curvas y formas cada vez más elaboradas.
Backpropagation	Se utiliza para ajustar los pesos de todas las interconexiones de las capas	Se utiliza para ajustar los pesos de los kernels.

Arquitectura básica.

- **Entrada:** Serán los píxeles de la imagen. Serán alto, ancho y profundidad será 1 sólo color o 3 para Red,Green,Blue.
- **Capa De Convolución:** procesará la salida de neuronas que están conectadas en “regiones locales” de entrada (es decir píxeles cercanos), calculando el producto escalar entre sus pesos (valor de pixel) y una pequeña región a la que están conectados en el volumen de entrada. Aquí usaremos por ejemplo 32 filtros o la cantidad que decidamos y ese será el volumen de salida.

Arquitectura básica.

- **“CAPA RELU”** aplicará la función de activación en los elementos de la matriz.
- **POOL ó SUBSAMPLING:** Hará una reducción en las dimensiones alto y ancho, pero se mantiene la profundidad.
- **CAPA “TRADICIONAL”** red de neuronas que conectará con la última capa de subsampling y finalizará con la cantidad de neuronas que queremos clasificar.